

Observatorio de Accidentalidad Vial en Colombia: Integración de Datos para la Toma de Decisiones

Jeferson Cardona — Daniela Baena | Introducción a la Analítica de Negocios | Universidad de Antioquia

Los siniestros viales en Colombia son una de las principales causas de muerte en el país, un problema que no ha disminuido pese a los esfuerzos institucionales. Solo en 2024 se registraron 8.479 muertes por siniestros viales, una tasa de 16,09 fallecidos por cada 100.000 habitantes, cifra que se mantiene en un nivel históricamente alto tras el repunte que siguió a la pandemia (Instituto Nacional de Medicina Legal y Ciencias Forenses [INMLCF], 2026).

En Colombia, como respuesta a esta problemática, se cuenta con el Observatorio Nacional de Seguridad Vial (ONSV), administrado por la Agencia Nacional de Seguridad Vial (ANSV), que se encarga de recopilar, analizar y divulgar información sobre los siniestros viales que ocurren en el país (Agencia Nacional de Seguridad Vial [ANSV], s.f.). Pese a que existe una fuente oficial de información, esta suele presentar estadísticas descriptivas de una sola fuente a la vez, sin integrar variables de otras entidades (población, contexto económico y laboral) que permitan explicar por qué la siniestralidad se concentra en determinados territorios o perfiles de víctima.

Esta es la necesidad de información que busca cubrir el presente observatorio: no duplicar las estadísticas ya publicadas, sino construir, a partir de la integración de varias fuentes, indicadores y relaciones que apoyen decisiones de priorización de intervenciones de seguridad vial por parte de entidades públicas y privadas.

Preguntas por resolver

Q1 — Territorial: ¿en qué departamentos se concentra la mayor frecuencia de siniestros viales, y qué patrones horarios y de causalidad asociados al medio de transporte ayudan a explicar por qué unos territorios son más propensos que otros?

Q2 — Sociodemográfica: ¿cómo varía la frecuencia y gravedad de los siniestros viales según el género, la escolaridad y el grupo de edad de las personas involucradas?

Q3 — Socioeconómica: ¿los departamentos con mayor tasa de desocupación y menor actividad económica concentran también una mayor frecuencia de siniestros de motociclistas, o esta relación no se sostiene al comparar el conjunto de departamentos?

Periodicidad del análisis

Las tres fuentes se actualizan con periodicidad anual, por lo que el observatorio está diseñado para ejecutarse una vez al año, en cuanto ANSV/ONSV y el DANE publiquen el cierre del período correspondiente:

<i>Fuente</i>	<i>Periodicidad de actualización</i>	<i>Cobertura histórica</i>
<i>ANSV/ONSV — Muertes por eventos de transporte</i>	Anual	Desde 2009
<i>ANSV/ONSV — Lesiones por eventos de transporte</i>	Anual	Desde 2015
<i>DANE — Mercado laboral por departamentos (GEIH)</i>	Anual	Serie histórica por departamento

La extracción se implementó en un notebook reproducible: todo el proceso corre con código, sin necesidad de entrar a una página, hacer clic en "descargar" o abrir un archivo manualmente.

- **Muertes y lesiones por eventos de transporte (INMLCF, vía datos.gov.co):** estas dos fuentes se piden directamente al servidor a través de su API pública (Socrata), usando la librería **requests**. La respuesta llega en formato JSON, que se convierte directo en una tabla de pandas. No hace falta usuario ni contraseña, y como es código, para tener los datos del año siguiente basta con volver a correr la misma celda: no hay que ir a buscar un nuevo archivo ni ajustar nada a mano.
- **Mercado laboral por departamentos — GEIH (DANE):** a diferencia de las anteriores, esta fuente no tiene API; el DANE solo publica un archivo Excel (.xls). Aun así, la descarga también quedó automatizada: **requests** trae el archivo directamente desde la URL del DANE (fue necesario simular que la petición viene de un navegador, porque el servidor bloquea las peticiones que no traen esa información) y el archivo se lee en memoria con **BytesIO**, sin llegar a guardarse en el computador. Además, en vez de decirle al código "los datos de tal departamento están en la fila 15, columna 3" (lo cual se rompería si el DANE cambia el orden), se programó una función que busca en cada hoja la palabra "Concepto", que es lo que marca dónde empieza cada bloque de departamento, y desde ahí extrae los datos. Así, aunque el DANE agregue una columna con un año nuevo, el proceso lo sigue leyendo bien sin que haya que tocar el código.

Estas dos extracciones quedaron guardadas como funciones reutilizables (**extraer_datos_socrata** y **extraer_geih**), a las que solo se les cambia la URL, las columnas que se necesitan o el rango de años. Esto significa que, para repetir el análisis el próximo año, no hay que reescribir el proceso: solo se actualiza ese rango de años y se vuelve a correr el notebook.

Integración de las fuentes en una base maestra

La integración combina dos operaciones distintas según el grano de cada fuente:

- **Apilamiento (muertes + lesiones):** ambas fuentes comparten exactamente el mismo esquema de 12 variables que elegimos (año, sexo, grupo de edad, escolaridad, estado civil, fecha y hora del hecho, departamento y municipio, circunstancia y condición de la víctima), por lo que se unen por filas en una sola tabla de víctimas, agregando una columna **gravedad_del_hecho** que distingue "Muerte" de "Lesionado".
- **Cruce por llave (víctimas + GEIH):** la GEIH tiene departamento-año, así que se integra a cada víctima mediante la llave compuesta departamento y año del hecho.

Homologación de variables, formatos y categorías

- **Nombres de variables:** la plataforma datos.gov.co entrega las columnas con nombres técnicos y poco intuitivos. Antes de unir muertes y lesiones, les pusimos a ambas bases los mismos nombres, simples y en español (por ejemplo, año, sexo, departamento), para que las dos tablas quedaran con columnas idénticas y se pudieran apilar una debajo de la otra sin descuadres.
- **Categorías:** el nombre del departamento venía escrito distinto entre fuentes — "Quindio" sin tilde en una y "Quindío" con tilde en otra, "Bogotá, D.C." con coma en una y "Bogotá D.C." sin coma en otra. Para nosotros es obvio que es el mismo lugar, pero para un cruce

por llave son dos departamentos distintos, así que esos registros se habrían perdido sin explicación. Se corrigió la escritura y se confirmó que, después del ajuste, muertes, lesiones y GEIH coincidieran en los mismos 23 departamentos.

- Formatos: se hicieron dos ajustes para que el cruce funcionara. Primero, el año del hecho venía como texto y se convirtió a número. Segundo, la GEIH original trae un formato ancho, con una columna por cada año (por ejemplo, Antioquia con 19 columnas, una por año desde 2007 hasta 2025); se transformó a un formato largo, con una fila por cada combinación de departamento y año, que es la forma que se necesita para cruzar usando departamento y año como llave.
- Unidades de medida: las tasas de ocupación, desocupación y subocupación quedaron todas en porcentaje, tanto en el total como en los desagregados de hombres y mujeres, para poder compararlas directamente sin conversiones adicionales.

Referencias

- Agencia Nacional de Seguridad Vial. (s. f.). Observatorio Nacional de Seguridad Vial. https://ansv.gov.co/observatorio/que_es_observatorio
- Instituto Nacional de Medicina Legal y Ciencias Forenses. (2026). Datos para la vida: Muertes por eventos de transporte.
- Departamento Administrativo Nacional de Estadística. (s. f.). Mercado laboral por departamentos (GEIH). <https://www.dane.gov.co>